INFORME DOCTORAL DE INVESTIGACIÓN CIENTÍFICA

Identificación de Vacíos de Conocimiento, Contradicciones Empíricas y Oportunidades Publicables en Seguridad de LLMs (2023–2026)

Autor: Pedro Giovanni Ricra Figueroa | **Institución:** Escuela Profesional de Ingeniería de Sistemas (EPIS-UNU)

Línea de Investigación: Ciberseguridad & Adversarial ML | **Marco Taxonómico:** MITRE ATLAS

1. Resumen Ejecutivo y Dictamen Crítico

A través de una auditoría exhaustiva de 4,037 registros bibliográficos crudos en 5 bases indexadas (Scopus, IEEE Xplore, ScienceDirect, EBSCO, IOPscience), la lectura integral de 10 investigaciones científicas primarias descargadas en PDF a texto completo y la consulta de la literatura internacional de frontera (2024–2026), este informe determina que **existe una oportunidad de investigación científica excepcional y publicable en revistas Q1**. La literatura actual presenta un agotamiento en la evaluación estática y descontextualizada de prompts individuales (single-turn) en laboratorio, pero evidencia fallas críticas e irresolutas en tres ejes: (1) el colapso ante ataques conversacionales progresivos multi-turno (Crescendo), (2) el trilema industrial de producción entre seguridad, sobre-bloqueo (over-refusal) y latencia, y (3) la total indefensión del canal de recuperación en RAG.

2. Inventario y Auditoría del Corpus Primario Examinado

Se verificó la disponibilidad de texto completo (100% accesible) de los 10 artículos fundamentales del repositorio, registrando su filiación, DOI y tipo de estudio:

ID	Artículo Científico / Autores	Año / Revista / DOI	Aporte & Enfoque Central
P-01	**Comprehensive Analysis of LLM Guardrails...** Majewski et al. (GART / PWR)	2026 | IEEE Access 10.1109/ACCESS.2026.3690365	Evalúa 4 guardrails comerciales ante 13 familias de jailbreak; mide exactitud (93.9-96.8%) pero revela over-refusal crítico (18.4% en XSTest) y latencia de hasta 620 ms.
P-02	**Hive-AI: Honeypot Framework for GenAI APIs** Vargas Yáñez & Tobón	2026 | Int. J. Inf. Sec. (Springer) 10.1007/s10207-026-01307-0	Analiza 16,683 ataques reales de 50 países en producción; demuestra que la decepción activa mediante honeypots reduce la evasión del 54.8% al 9.3% (-45.5 pp).
P-03	**PROMPT FUZZ: Fuzzing for Prompt Injection** Yu, Shao, Miao & Shi	2024/2026 | IEEE TDSC / S&P; arXiv:2309.05610	Framework de fuzzing mutacional semántico guiado por fitness; supera el red-teaming manual con ASR > 82.4% y elude filtros de Azure y OpenAI en 65% de casos.
P-04	**RigorLLM: Resilient Guardrails for LLMs** Yuan, Xiong, Zeng, Song, Li et al.	2024/2026 | USENIX Security arXiv:2403.13031	Guardrail compuesto con Langevin dynamics para datos sintéticos, sufijos minimax y fusión KNN+LLM; alta resiliencia contra ataques de optimización GCG.
P-05	**BackdoorAlign: Mitigating FJAttack** Wang, Li, Qi, McDaniel, Li, Xiao et al.	2024/2026 | Findings of ACL arXiv:2402.14968	Alineamiento con triggers secretos de backdoor en LMaaS; defiende contra desalineación por fine-tuning requiriendo solo 1% de datos de seguridad adicionales.
P-06	**Ranking Manipulation for Search Engines** Pfrommer, Bai, Gautam & Sojoudi	2024 | EMNLP (ACL) 10.18653/v1/2024.emnlp-main.533	Demuestra secuestro de rankings comerciales en RAG (Perplexity/Bing) vía inyecciones indirectas en páginas web; promociona productos al Top-1 en 87.5% de casos.
P-07	**Privacy-Preserving Middleware Architecture** Ait Hsine & Arabo	2026 | MDPI Electronics 10.3390/electronics15163554	Middleware local híbrido con SLM fine-tuneado y enrutamiento sensible; 95.83% exactitud reteniendo datos confidenciales dentro de la frontera corporativa.

P-08	**Ignore This Title and HackAPrompt** Schulhoff, Pinto, Boyd-Graber et al.	2023 | EMNLP (ACL) 10.18653/v1/2023.emnlp-main.302	Dataset masivo de 600K+ prompts generados por humanos; prueba empíricamente que humanos superan sistemáticamente 10 niveles de defensas por prompt engineering.
P-09	**Adversarial Attacks on Medical LLMs** Yang, Jin, Huang & Lu	2025/2026 | Nature Communications 10.1038/s41467-025-64062-1	Demuestra que 10-50 muestras envenenadas provocan prescripciones letales en el 62% de casos en Med-PaLM y GPT-4 sin degradar el puntaje en exámenes USMLE.
P-10	**A Decontextualized Safeguard (D-SHIELD)** Santilli, De Luca, Pelliccione et al.	2026 | Inf. & Software Tech. 10.1016/j.infsof.2026.107621	Descubre la 'contaminación contextual' del moderador; demuestra que evaluar solo la respuesta descontextualizada eleva la mitigación del 68.2% al 94.7% con -38% latencia.

3. Contradicciones Científicas Estructurales Detectadas

1. Paradoja de Eficacia vs. Over-Refusal: Majewski et al. revelan que los guardrails industriales sufren hasta 18.4% de sobre-bloqueo en prompts limítrofes legítimos, mientras Ait Hsine reporta 0% falsos positivos debido a una muestra sesgada de solo 120 prompts.
2. Doctrina de Contextualización: Santilli demuestra que incluir el prompt del atacante contamina al evaluador reduciendo la mitigación al 68.2%, pero los estándares industriales (Llama Guard) consideran obligatoria la contextualización para entender la intención del usuario.
3. Respuesta de Bloqueo vs. Decepción: Mientras la industria impone bloqueo rígido inmediato (HTTP 403), Vargas Yáñez demuestra que esto genera 54.8% de evasión en producción, reduciéndose al 9.3% únicamente cuando se emplean fachadas sintéticas de honeypot.

4. Priorización Científica y Propuesta Recomendada

Se evaluaron 6 oportunidades de investigación mediante una rúbrica de 100 puntos (Novedad 25, Importancia 20, Evidencia 20, Viabilidad 15, Reproducibilidad 10, Publicación 10).

Rank	ID	Título de la Propuesta	Nov.	Imp.	Evid.	Viab.	Repr.	Pub.	Total
1	P-INV-01	**Moderación Desacoplada con Atención Asimétrica contra Contaminación Multi-Turno**	24	19	19	14	9	9	**94**
2	P-INV-02	Framework Pareto-Eficiente para Guardrails en Producción (ASR vs. Over-Refusal)	22	19	19	15	10	8	**93**
3	P-INV-03	ShieldRank: Re-Ranking Robusto Criptográfico contra RAG Poisoning	23	19	18	13	9	9	**91**
4	P-INV-04	Protocolo MAC y Taint Tracking para Enjambres Multi-Agente (MCP)	25	20	19	9	6	10	**89**
5	P-INV-05	Honeypots Semánticos con Aislamiento Transaccional Copy-On-Write	22	17	18	13	8	8	**86**
6	P-INV-06	Verificación Formal Ontológica de Adaptadores LoRA en Dominio Clínico	24	18	17	11	7	9	**86**

5. Plan de la Investigación Recomendada: AAM-Guard (P-INV-01)

Título Definitivo: *Desacoplamiento de Atención Asimétrica para la Mitigación de Contaminación Contextual en Moderadores de Lenguaje ante Ataques de Jailbreak Conversacionales Multi-Turno.*
Problema Técnico: La descontextualización total (D-SHIELD) falla en el turno 3 de una conversación porque la respuesta pierde sentido sin las referencias previas, disparando falsos positivos. Llama Guard 3, al leer todo el chat, es intoxicado por el ataque Crescendo.
Solución Propuesta: Diseñar **AAM-Guard**, que enmascara selectivamente en la matriz de atención los tokens persuasivos y de rol del atacante ($-\infty$), permitiendo a los tokens de respuesta atender únicamente a entidades y dependencias factuales declarativas del historial.
Diseño Experimental: Factorial 3×4 evaluando 3 moderadores (Llama Guard 3, D-SHIELD, AAM-Guard) ante 500 diálogos multi-turno (Crescendo, Persona Drift, GCG fragmentado y controles benignos de XSTest) de hasta 15 turnos.
Metas Cuantitativas: Incrementar la mitigación (AMR) en ≥ 20 puntos porcentuales frente a Llama Guard 3, mantener over-refusal $\le 3.5\%$ y latencia añadida < 60 ms en una GPU de 24 GB.
Revista Objetivo: *Information and Software Technology* (Elsevier, Q1) o *IEEE Transactions on Information Forensics and Security* (Q1).

6. Índice y Trazabilidad de Artefactos Generados

Todos los archivos de soporte técnico y experimental han sido generados en la carpeta analisis_vacios_cientificos/:
• **01_inventario_documental.xlsx:** Catálogo completo de 21 fuentes primarias auditadas.
• **02_matriz_comparativa_investigaciones.xlsx:** Respuestas detalladas a las 15 preguntas por estudio y análisis de tensiones.
• **03_mapa_estado_del_arte.md:** Reconstrucción taxonómica integral de Categorías A a F bajo MITRE ATLAS.
• **04_matriz_vacios_conocimiento.xlsx:** 7 vacíos consolidados en 5 dimensiones y taxonomía de entornos experimentales.
• **05_contradicciones_cientificas.md:** Análisis epistemológico de 5 contradicciones empíricas profundas.
• **06_validacion_externa_vacios.md:** Búsquedas de literatura externa de frontera (2024–2026) en USENIX, ICML, EMNLP.
• **07_oportunidades_investigacion.md:** 6 propuestas completas con los 24 campos metodológicos exigidos.
• **08_ranking_novedad_y_viabilidad.xlsx:** Evaluación con rúbrica de 100 puntos y justificación desglosada.
• **09_propuesta_investigacion_recomendada.md:** Plan formal de artículo científico y tesis para P-INV-01.
• **10_referencias_bibliograficas.bib:** Base BibTeX con DOIs verificables de toda la literatura citada.
• **INFORME_FINAL_VACIOS_CIENTIFICOS.pdf:** El presente documento formal de síntesis doctoral.