UNIVERSIDAD NACIONAL DE UCAYALI

ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS

Vulnerabilidades y técnicas de evasión de seguridad en Modelos de Lenguaje Grande desplegados en producción

Mapeo Sistemático (Scoping Review) | 2023–2026

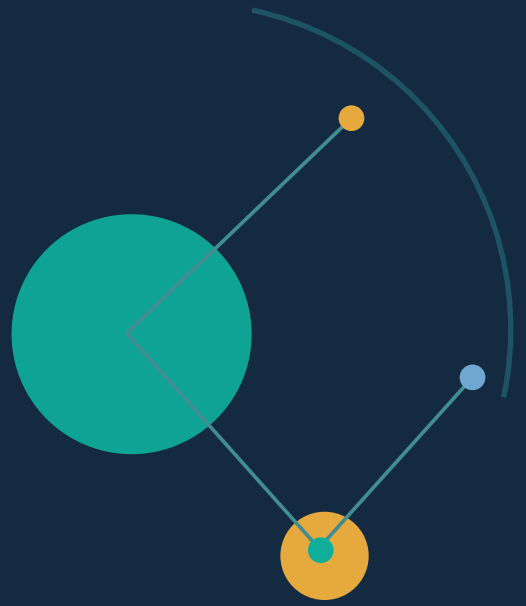
CIBERSEGURIDAD

SEGURIDAD DE LLMs

Presentado por

Pedro Giovanni Ricra Figueroa

Trabajo de Investigación • Ciclo X • Noviembre 2026



¿Qué se investiga?

El punto de partida es el tema oficial definido para el proyecto.

Línea de investigación

Ciberseguridad

Tipo de revisión

Mapeo Sistemático (Scoping Review)

Periodo de evidencia

Publicaciones y preprints 2023–2026

OBJETO DE ESTUDIO

Vulnerabilidades, técnicas de evasión y mecanismos de defensa algorítmica en LLMs desplegados en producción.

El análisis se centra en la evidencia científica; no propone desarrollar un nuevo modelo ni implementar una defensa propia.

Situación problemática

La exposición de los LLMs en aplicaciones y sistemas agénticos amplía la superficie de ataque.

PROBLEMA CENTRAL

Los LLMs procesan instrucciones y datos no confiables en un mismo canal semántico.

Esto puede permitir que entradas manipuladas alteren el comportamiento del modelo o eludan los mecanismos de protección.

Necesidad: organizar la evidencia sobre ataques, defensas, eficacia reportada y limitaciones.

VECTORES QUE DELIMITAN EL ESTUDIO

01 **Prompt Injection**

Inyección directa e indirecta de instrucciones no confiables.

02 **Jailbreaking**

Técnicas adversariales para evadir restricciones de seguridad.

03 **Data Poisoning**

Envenenamiento de datos y manipulación del conocimiento, incluido RAG.

Pregunta y objetivo de investigación

Se conservan las formulaciones establecidas en el tema oficial.

PREGUNTA DE INVESTIGACIÓN

¿Cuáles son las principales vulnerabilidades y técnicas de evasión de seguridad en Modelos de Lenguaje Grande (LLMs) desplegados en producción?

OBJETIVO GENERAL

Identificar y categorizar vectores de ataque contra LLMs (Prompt Injection, Data Poisoning, Jailbreaking) y las defensas algorítmicas actuales.

COHERENCIA

La pregunta delimita el fenómeno; el objetivo define la clasificación y síntesis que realizará el mapeo.

Delimitación cuatridimensional

La matriz organiza el alcance en cuatro dimensiones para evitar que el objeto de estudio se disperse.

1. Temática y tecnológica

LLMs fundacionales; guardrails y defensas algorítmicas. Ataques: inyección directa/indirecta, jailbreak y envenenamiento, incluida la manipulación en RAG.

2. Espacial

Literatura científica internacional. Adscripción académica: Escuela Profesional de Ingeniería de Sistemas, Universidad Nacional de Ucayali, Pucallpa, Perú.

3. Temporal

Publicaciones elegibles: 2023–2026. Periodo académico de ejecución: semestre 2026-II.

4. Unidad de análisis / población

Publicaciones científicas arbitradas, actas de congresos, preprints de alto impacto y reportes de evaluación de seguridad de LLMs.

Estrategia de búsqueda

La ecuación combina el objeto tecnológico, los vectores adversariales y el ámbito de seguridad/defensa.

ECUACIÓN DE BÚSQUEDA

("large language model*" OR LLM OR LLMs OR "foundation model*")

AND ("prompt injection" OR jailbreak* OR "data poisoning" OR "adversarial machine learning" OR "AI red teaming")

AND ("LLM security" OR "language model security" OR vulnerab* OR attack* OR evasion OR defense OR defence OR mitigation OR detection OR guardrails)

BASES MARCADAS COMO CONSULTADAS EN LA MATRIZ

- Scopus
- IEEE Xplore
- ScienceDirect
- IOP Science
- EBSCOhost

SciELO también figura entre las bases sugeridas en tema.md; no está marcada como consultada en esta matriz.

DESCRIPTORES CLAVE

- LLM security
- prompt injection
- adversarial machine learning
- jailbreak
- data poisoning
- AI red teaming

Criterios de inclusión y exclusión

Los criterios mantienen la revisión centrada en la seguridad de modelos fundacionales.

INCLUSIÓN

- Estudios empíricos, teóricos y revisiones cuyo objeto central sean LLMs, agentes basados en LLMs o sistemas RAG.
- Publicaciones en español o inglés, entre 2023 y 2026.
- Estudios sobre Prompt Injection, Jailbreaking, Data/RAG Poisoning y/o defensas algorítmicas.
- Texto completo accesible para asegurar trazabilidad y análisis.

EXCLUSIÓN

- ML/DL convencional sin relación con LLMs o modelos fundacionales.
- Ciberseguridad tradicional sin relación con lenguaje natural o modelos generativos.
- Metadatos de actas o portadas sin aporte de investigación individual.
- Duplicados y versiones preliminares superadas por publicación definitiva.

Nota metodológica: la matriz condiciona la inclusión al acceso a texto completo; conviene registrar por separado los documentos no recuperados.

Resultados preliminares de búsqueda y selección

Cifras declaradas en la matriz; deben entenderse como un avance de depuración y cribado.

4,037
Registros recuperados
5 bases de datos

→

3,273
Registros únicos reportados
Tras deduplicación y filtros iniciales

→

12
Artículos preseleccionados
Coincidencia temática

→

10
Estudios a texto completo
Muestra fundamental indicada

CONTROL DE CONSISTENCIA DE CIFRAS

4,037 − 685 duplicados = 3,352; la matriz reporta 3,273. La diferencia de 79 registros debe desglosarse como exclusiones por periodo/idioma u otro filtro y verificarse con el registro de búsqueda.

No presentar las 10 investigaciones como población final hasta completar y documentar todas las fases de selección.

Estudios que respaldan la delimitación

La matriz selecciona tres fuentes para ilustrar los principales frentes del problema.

01

Majewski et al. (2026)

IEEE Access

Evaluación comparativa de guardrails

Compara mecanismos de defensa comerciales y de código abierto frente a ataques de jailbreak. La matriz destaca la evaluación de exactitud, variedad de ataques y sobre-bloqueo.

02

Santilli et al. (2026)

Information and Software Technology

D-SHIELD y contaminación contextual

Analiza una técnica de salvaguarda descontextualizada y la influencia del prompt manipulativo sobre el moderador de seguridad.

03

Vargas Yáñez & Tobón (2026)

International Journal of Information Security

HIVE-AI y defensa activa

Presenta un framework de honeypot para APIs de IA generativa y evidencia empírica sobre técnicas de evasión en escenarios de producción.

Estas fuentes sustentan el alcance; no sustituyen el análisis completo de todos los documentos elegibles.

¿Cómo se organizará la evidencia?

La síntesis responde al objetivo: identificar y categorizar ataques y defensas, no probar una arquitectura propia.

1. Ataques

Prompt Injection
Jailbreaking
Data / RAG Poisoning

2. Contexto

Modelo y aplicación
Producción / laboratorio
Vector y superficie

3. Defensas

Guardrails
Detección y filtrado
Alineación y mitigación

4. Evidencia

Métricas y resultados
Limitaciones
Vacíos de conocimiento

MARCO DE CLASIFICACIÓN

MITRE ATLAS

Taxonomía de amenazas y técnicas adversariales para ordenar los ataques identificados.

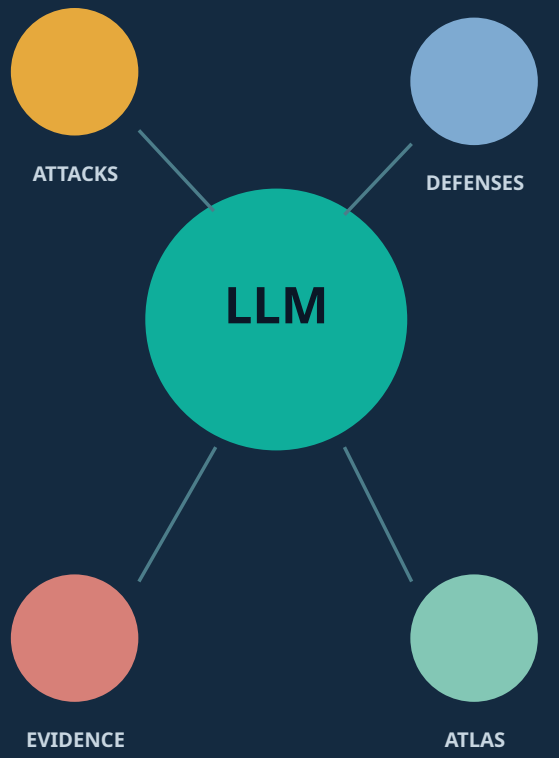
Resultado de la síntesis: mapa de ataques, defensas, condiciones de evaluación y limitaciones reportadas.

10 · RESULTADO ESPERADO

¿Qué aportará el mapeo sistemático?

01	**Taxonomía de ataques**	Clasificación de Prompt Injection, Jailbreaking y Data Poisoning.
02	**Mapa de defensas**	Síntesis de guardrails y mecanismos algorítmicos reportados.
03	**Lectura crítica**	Comparación de contextos, métricas, resultados y limitaciones.
04	**Vacíos de evidencia**	Identificación de aspectos insuficientemente estudiados.

La contribución será una síntesis estructurada y trazable de la evidencia disponible entre 2023 y 2026.



GRACIAS

¿Preguntas?